Karadeniz Teknik Üniversitesi

Bilgisayar Mühendisliği – Yazılım Mühendisliği Dersi

Genetik Varyant Patojenite Tahmin Sistemi

Gereksinim Analizi Raporu

Grup Üyeleri

Ad Soyad	Öğrenci No	Üstlendiği İş	GitHub
Nida Aktuğ	434323	GitHub takibi	nida-ktg
Gülderen Buse Söylemez	434354	Gereksinim türlerinin belirlenmesi, görev dağılımı ve Gereksinim Raporu'nun derlenmesi.	Gulderenbuse
Zeynep Bahar Ortaeri	434396	Üst tasarım ,mimari rapor	baharo
Feyzanur Tellioğlu	[No]	Genel koordinasyon, sunum sırasının organizasyonu ve aktivitelerin standartlara uygunluğunun takibi.	FeyzaNur-codes
Haticegül Nişancı	434378	Test ve dokümantasyon	htcgulnisanci-hub

1. Giriş

1.1 Projenin Amacı

Bu projede, insan genomunda görülen genetik varyantların (mutasyon ya da polimorfizm) hastalık yapıcı (Patojenik) mi yoksa zararsız (Benign) mi olduğunu tahmin eden bir yapay zeka modeli geliştireceğiz.

Genetik varyantları yorumlamak normalde uzman genetikçilerin saatler harcadığı, yorucu bir süreç. Biz bunu otomatikleştiren, hızlı ve tutarlı sonuçlar veren bir sistem yapmak istiyoruz.

1.2 Ne Yapacağız?

- **Veri:** ClinVar, gnomAD gibi açık veri tabanlarından etiketli varyant verisi toplayacağız.
- **Model:** Birden fazla özelliği (SIFT, PolyPhen, CADD vb.) kullanan bir sınıflandırma modeli eğiteceğiz.
- **Çıktı:** Her varyant için Patojenik / Benign / Belirsiz etiketi ve güven skoru üretilecek.
- **Arayüz:** Kullanıcıların varyant girip sonuç alabileceği basit bir web arayüzü yapacağız.

1.3 Terimler

Terim	Ne Demek?
SNV	Tek baz değişikliği olan varyant türü
InDel	Küçük ekleme ya da silinme varyantı
VUS	Patojenik mi zararsız mı belirsiz olan varyant
MAF	Bir varyantın toplumda görülme sıklığı
ACMG	Varyant yorumlamak için yaygın kullanılan kılavuz
CADD	Varyantın zararlılığını puanlayan bir skor

2. Kimler Etkileniyor? (Paydaşlar)

Bu sistemi kim kullanacak, kimin işine yarayacak, bunları belirlemek önemliydi. Görüşmeler ve beyin fırtınası yaparak şu paydaşları tespit ettik:

Paydaş	Ne İşe Yarayacak?	Önem
Klinik Genetikçiler	Ana kullanıcı – varyant yorumlamada karar verirken kullanacaklar	Yüksek
Biyoinformatikçiler	Modeli geliştirip veri boru hattını kuracaklar	Yüksek
Hastalar	Doğru tanıdan doğrudan yararlanacaklar	Yüksek
Hastane / Tanı Merkezi	Sistemin klinik iş akışına entegre edileceği yer	Orta
Proje Danışmanı	Akademik değerlendirme yapacak	Orta
Geliştirme Ekibi	Sistemi inşa edip bakımını yapacak olan biz 😊	Yüksek

2.1 Gereksinimleri Nasıl Topladık?

Aşağıdaki teknikleri kullandık:

- Görüşmeler – Genetikçilerle ne istediklerini konuştuk
- Anketler – Potansiyel kullanıcılara online anket gönderdik
- Çalıştaylar – Paydaşlarla birlikte oturup gereksinimler üzerine çalıştık
- Beyin fırtınası – Ekip içi fikir üretme seansları düzenledik
- Kullanım senaryoları – "Kullanıcı şunu yapmak isterse ne olur?" diye düşündük
- Prototipleme – Basit arayüz taslakları çizip geri bildirim aldık

3. Fonksiyonel Gereksinimler

Yani sistem ne yapabilmeli? İşte temel maddeler:

3.1 Veri Toplama ve Hazırlama

- **FR-01** Sistem, ClinVar ve gnomAD'dan otomatik olarak varyant verisi çekebilmeli.
- **FR-02** VCF formatındaki dosyaları okuyabilmeli ve işleyebilmeli.
- **FR-03** Eksik veya hatalı veriler tespit edilip raporlanmalı.
- **FR-04** Her varyant için SIFT, PolyPhen-2, CADD gibi skorlar hesaplanmalı veya entegre edilmeli.
- **FR-05** Popülasyondaki görülme sıklığı (MAF) gnomAD'dan çekilmeli.

3.2 Model Eğitimi

- **FR-06** En az birkaç farklı ML algoritması denenebilmeli (Rastgele Orman, XGBoost, derin öğrenme).
- **FR-07** Veri; eğitim/doğrulama/test olarak ayrılmalı, çapraz doğrulama kullanılmalı.
- **FR-08** AUC-ROC skoru en az 0.90 olmalı – bu hedefimiz.
- **FR-09** Sınıf dengesizliğiyle baş etmek için SMOTE ya da ağırlıklı kayıp fonksiyonu uygulanmalı.

3.3 Tahmin

- **FR-10** Her varyant için üç olası sonuçtan biri üretilmeli: Patojenik, Benign veya Belirsiz (VUS).
- **FR-11** Tahminle birlikte 0–1 arası güven skoru da verilmeli.
- **FR-12** Sonuçlar ACMG standardına göre etiketlenmeli.
- **FR-13** Hangi özelliğin kararı nasıl etkilediğini göstermek için SHAP kullanılmalı ("neden böyle tahmin etti" sorusunun cevabı).

3.4 Arayüz ve API

- **FR-14** Kullanıcı tek varyant girebilmeli ya da VCF dosyası yükleyebilmeli.
- **FR-15** Sonuçlar görselli bir rapor olarak sunulmalı (tablo + grafik).
- **FR-16** REST API, JSON formatıyla çalışmalı.
- **FR-17** Kullanıcı sonuçları PDF veya CSV olarak indirebilmeli.

4. Fonksiyonel Olmayan Gereksinimler

Yani sistem nasıl çalışmalı?

4.1 Hız

- **NFR-01** Tek varyant tahmini 2 saniyeden uzun sürmemeli.
- **NFR-02** 1000 varyantlık toplu analiz 10 dakikada bitmeli.
- **NFR-03** Sistem aynı anda en az 50 kullanıcıyı kaldırabilmeli.

4.2 Güvenilirlik

- **NFR-04** Sistem yılın %99.5'inde çalışır durumda olmalı.
- **NFR-05** Aynı girdi her zaman aynı çıktıyı vermeli.

4.3 Güvenlik

- **NFR-06** API trafiği şifreli (TLS) olmalı.
- **NFR-07** Giriş yapmak için JWT tabanlı doğrulama kullanılmalı.
- **NFR-08** Hasta verileri KVKK ve GDPR'a uygun işlenmeli; anonimleştirilmeli.

4.4 Taşınabilirlik

- **NFR-09** Her şey Docker ile paketlenmeli – farklı bilgisayarlarda da çalışsın.
- **NFR-10** Yeni bir veri tabanı eklemek kolayca mümkün olabilmeli; modüler yapı şart.

5. Gereksinimleri Nasıl Yöneteceğiz?

5.1 Belgeleme

Topladığımız tüm gereksinimleri bu raporda yazılı hale getirdik. Her gereksinim bir kod aldı (FR-XX veya NFR-XX) ki takibi kolay olsun.

5.2 Doğrulama ve Onay

Gereksinimlerin doğruluğunu danışmanımız ve klinik genetikçilerle birlikte kontrol ettik. Onaylanan gereksinimler hem biz hem paydaşlar arasında ortak bir anlayış zemini oluşturuyor.

5.3 Değişiklik Olursa?

Proje boyunca gereksinimler değişebilir. Bunu şöyle yönetiyoruz:

- Değişiklik talebi Git Issues üzerinden açılır.
- Ekip etkisini değerlendirir, öncelik belirler.
- Onaylanırsa bu rapor güncellenir, versiyon numarası artar.

5.4 Önceliklendirme

Her şeyi aynı anda yapmak mümkün değil. Bu yüzden gereksinimleri önceliğe göre sıraladık:

Öncelik	Hangi Gereksinimler?	Ne Zaman?
P1 – Olmazsa Olmaz	FR-01 – FR-11, NFR-06 – NFR-08	İlk sürümde mutlaka olacak
P2 – Önemli	FR-12 – FR-15, NFR-01 – NFR-05	İlk sürümde olmaya çalışacağız
P3 – Güzel Olur	FR-16, FR-17, NFR-09, NFR-10	İkinci sürüme bırakılabilir

6. Kullanım Senaryoları

Senaryo 1: Tek Varyant Sorgulama

Kim kullanıyor?	Klinik genetikçi

Ne yapmak istiyor?	Elindeki bir varyantın zararlı olup olmadığını öğrenmek
Nasıl kullanıyor?	Varyant kodunu (örn. rs123456) arayüzden giriyor → sistem analiz yapıyor → Patojenik/Benign/VUS sonucu ve güven skoru ekrana geliyor
Ek özellik	SHAP grafiğiyle hangi özelliğin kararı nasıl etkilediğini de görebiliyor
Çıktı	Sonuç PDF olarak indirilebiliyor

Senaryo 2: Toplu VCF Dosyası Analizi

Kim kullanıyor?	Biyoinformatikçi veya laboratuvar
Ne yapmak istiyor?	Yüzlerce varyantı tek seferde analiz etmek
Nasıl kullanıyor?	VCF dosyasını yüklüyor → sistem paralel işliyor → her varyant için tahmin üretiyor
Çıktı	Tüm sonuçları içeren CSV veya PDF raporu indirilebiliyor

7. Veri Gereksinimleri

7.1 Eğitim Verisi

- En az 200.000 etiketli varyant kullanılacak (en az %40'ı Patojenik).
  - Veriler ClinVar (güvenilirlik yıldızı ≥ 2) ve HGMD'den çekilecek.
- Test seti eğitim setiyle örtüşmemeli – gen bazlı ayrım uygulanacak.

7.2 Hangi Özellikler Kullanılacak?

Özellik Grubu	Örnekler
Sekans bilgisi	Hangi alel değişti, nerede gerçekleşti, protein'i etkiliyor mu?
Protein etki skorları	SIFT, PolyPhen-2, MutPred2, PROVEAN
Evrimsel koruma	GERP++, PhyloP, CADD – bu baz ne kadar korunmuş?
Popülasyon sıklığı	gnomAD MAF – bu varyant toplumda ne sıklıkta görülüyor?
Klinik geçmiş	ClinVar'da kaç hastalıkla ilişkilendirilmiş?
Splicing tahmini	SpliceAI – RNA birleşme bölgesini etkiliyor mu?

8. Proje Planı

Aşama	Ne yapılacak?	Süre	Kim?
Gereksinim Analizi	Paydaş görüşmeleri, bu raporun yazılması	2 hafta	Herkes
Veri Toplama	ClinVar/gnomAD indirme, temizleme, özellik hesaplama	3 hafta	Veri ekibi
Model Geliştirme	Farklı modeller deneme, en iyisini seçme	4 hafta	ML ekibi
Değerlendirme	Test, karşılaştırma, bias analizi	2 hafta	Herkes
API & Arayüz	REST API, web sayfası, SHAP görselleştirme	3 hafta	Backend/ Frontend
Test	Birim test, entegrasyon testi, kullanıcı testi	2 hafta	Test ekibi
Rapor & Sunum	Final raporu yazma, sunum hazırlama	1 hafta	Herkes

9. Test ve Kabul Kriterleri

9.1 Ne Test Edilecek?

- Veri işleme fonksiyonları (birim testler)
- Uçtan uca boru hattı: veri girişi → model → API yanıtı
- API uç noktaları – hem geçerli hem hatalı girdilerle
- Model; daha önce hiç görmediği bir test kümesiyle değerlendirilecek

9.2 Başarı Kriterleri

Ne ölçüyoruz?	Hedefimiz	Alt sınır
AUC-ROC	≥ 0.92	0.90
Duyarlılık (Sensitivity)	≥ 0.90	0.88
Özgüllük (Specificity)	≥ 0.90	0.88
Tek tahmin süresi	≤ 1.5 sn	2 sn
1000 varyant analizi	≤ 7 dk	10 dk

---

10. Kaynaklar

- ClinVar – https://www.ncbi.nlm.nih.gov/clinvar/
- gnomAD – https://gnomad.broadinstitute.org/
- ACMG/AMP Varyant Yorumlama Kılavuzu – Richards et al. (2015)
- CADD – Kircher et al. (2014), Nature Genetics
- SHAP – Lundberg & Lee (2017), NeurIPS
- SpliceAI – Jaganathan et al. (2019), Cell
- Kullanılan kütüphaneler: scikit-learn, XGBoost, PyTorch, FastAPI