Karadeniz Teknik Üniversitesi
Bilgisayar Mühendisliği Bölümü
Yazılım Mühendisliği Dersi

VUSassistant

Proje Sonuç Raporu

Proje Konusu: Missense Genetik Varyantların Patojenite Tahmini (Web Sitesi)

VUSassistant

Proje Git Reposu: https://github.com/nida-ktg/VUSassistant

GRUP ÜYELERİ

Ad Soyad	Öğrenci No	Görev	GitHub
Nida Aktuğ	434323	GitHub takibi	nida-ktg
Feyza Nur Tellioğlu	434400	Genel koordinasyon, sunum sırasının organizasyonu ve aktivitelerin standartlara uygunluğunun takibi.	FeyzaNur-codes
Zeynep Bahar Ortaeri	434396	Üst tasarım ,mimari rapor	baharo
Gülderen Buse Söylemez	434354	Gereksinim türlerinin belirlenmesi, görev dağılımı ve Gereksinim Raporu'nun derlenmesi.	Gulderenbuse
Haticegül Nişancı	434378	Test ve dokümantasyon	htcgulnisanci-hub

1. Giriş ve Proje Konusu

Genetik varyantların klinik yorumlanması, modern tıpta en kritik ve en karmaşık süreçlerden biridir. Özellikle VUS (Variant of Uncertain Significance) olarak adlandırılan belirsiz varyantların değerlendirilmesi, klinisyenler için hem zaman alıcı hem de hata riski yüksek bir görevdir.

Bu proje kapsamında geliştirilen VUSassistant, genetik varyantların patojenik (zararlı), benign (zararsız) veya belirsiz (VUS) olup olmadığını tahmin eden yapay zeka destekli bir web tabanlı analiz sistemidir. Sistem, ClinVar Conflicting Dataset (61.000 varyant kaydı) kullanılarak eğitilmiş ve klinisyenlere risk skoru ile birlikte açıklanabilir tahminler sunmaktadır.

Projenin Amacı

- Klinik genetikte yanlış negatif (FN) oranını minimize etmek.

- Varyantların otomatik, hızlı ve güvenilir şekilde sınıflandırılmasını sağlamak.

- Açıklanabilir yapay zeka (XAI) ile klinisyenlerin kararlarını desteklemek.

- Web tabanlı arayüz ile kullanıcı dostu bir sistem geliştirmek.

Kullanılan Veri Seti: ClinVar Conflicting Dataset (61.000 varyant kaydı) — Her kayıt 9 sayısal + 8 kategorik özellik içermekte olup toplam 129 özelliğe genişletilmiştir.

Görsel 1ve görsel 2: Giriş ekranı ve kayıt ekranı (Doktorların güvenli giriş yaptığı KVKK uyumlu arayüz)

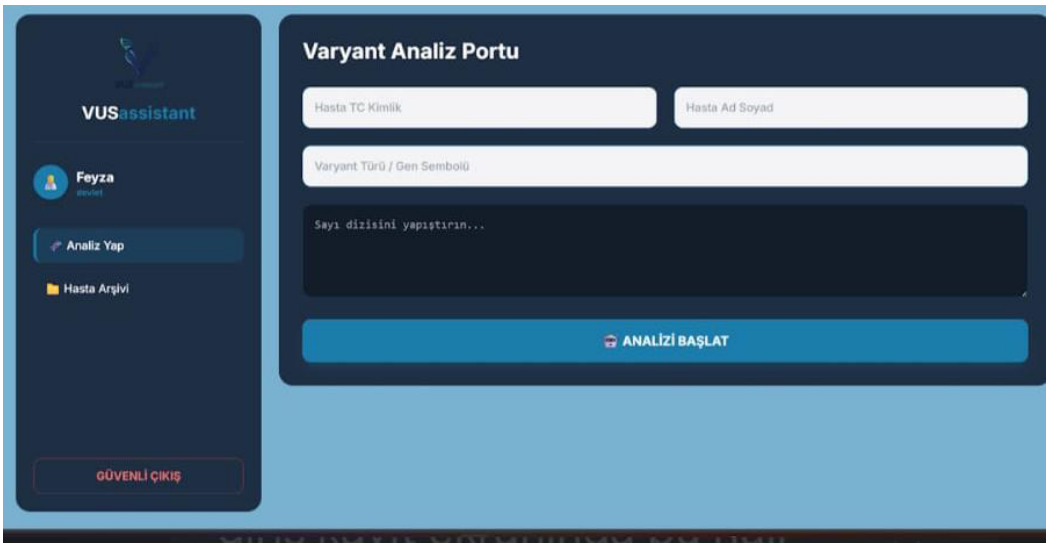

Görsel 3: Hastanın verilerinin giriş ve analiz sonuç ekranı

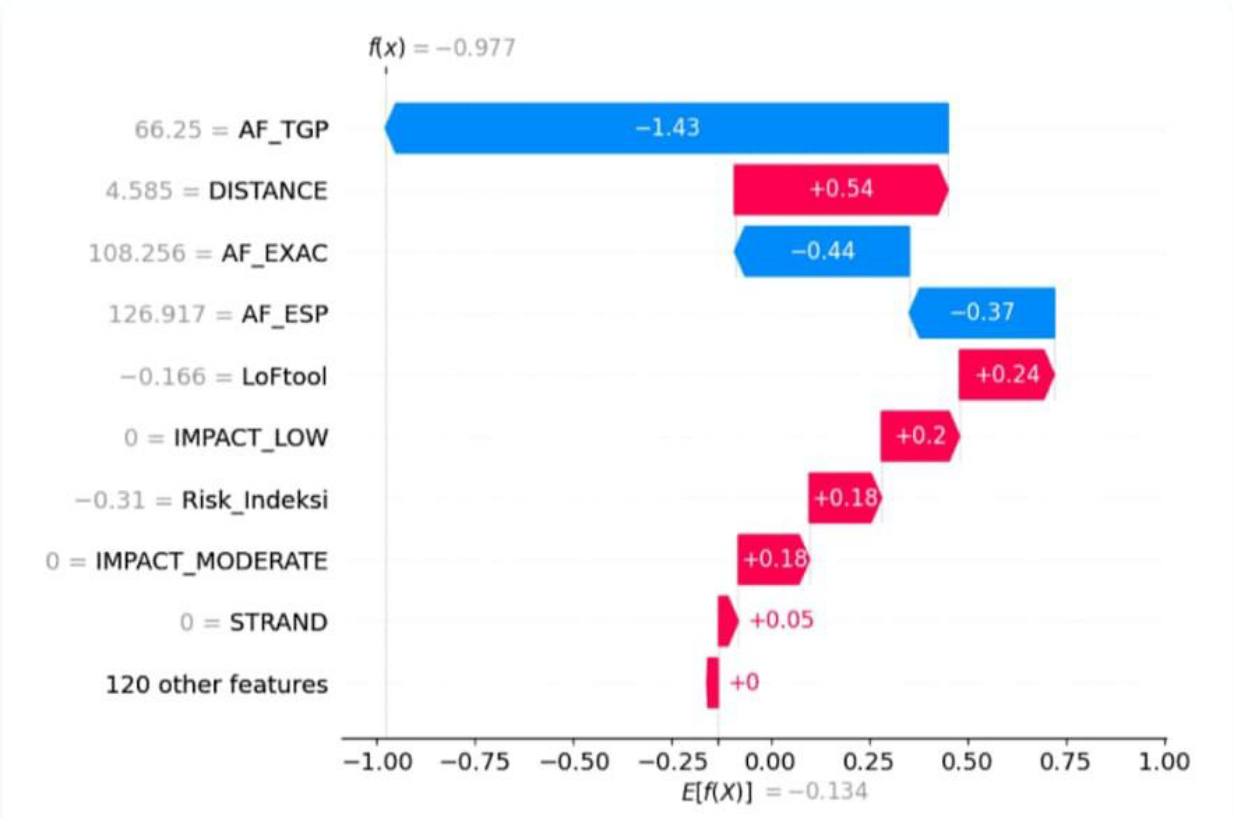

Görsel 4: Analiz edilen verinin SHAP grafiği

2. Yazılım Geliştirme Süreci ve GitHub Yönetimi

Proje geliştirme sürecinde ekip içi koordinasyonu sağlamak ve kod yönetimini düzenli şekilde gerçekleştirebilmek amacıyla Git ve GitHub tabanlı sürüm kontrol sistemi kullanılmıştır.

Tüm geliştirme süreçleri ortak GitHub reposu üzerinden yürütülmüş, takım üyeleri yaptıkları değişiklikleri branch yapısı kullanarak sisteme entegre etmiştir. Böylece farklı geliştirme süreçlerinin birbirinden bağımsız ilerlemesi ve kod çakışmalarının azaltılması amaçlanmıştır.

Proje kapsamında temel olarak aşağıdaki branch yapıları kullanılmıştır:

- **web branch'i:**
  Frontend geliştirmeleri, kullanıcı arayüzü tasarımları ve web tabanlı işlemler bu branch üzerinde gerçekleştirilmiştir. React tabanlı arayüz geliştirmeleri ve kullanıcı deneyimi çalışmaları bu bölümde yürütülmüştür.
- **machine-learning branch'i:**
  Yapay zeka modeli geliştirme, veri ön işleme, model eğitimi, SHAP analizleri ve tahminleme süreçleri bu branch üzerinde geliştirilmiştir.

Kod geliştirme sürecinde takım üyeleri düzenli olarak commit işlemleri gerçekleştirmiş, yapılan değişiklikler kontrol edildikten sonra ana projeye entegre edilmiştir.

Bu yapı sayesinde:

- Modüler geliştirme sağlanmış,
- Takım üyelerinin eş zamanlı çalışabilmesi kolaylaştırılmış,
- Kod takibi ve sürüm yönetimi daha düzenli hale getirilmiştir.

3. Gereksinim Analizi

Proje geliştirme sürecinin başlangıcında sistemin ihtiyaçları detaylı şekilde analiz edilmiştir. Gereksinimler fonksiyonel ve fonksiyonel olmayan gereksinimler olarak iki ana grupta değerlendirilmiştir.

3.1 Fonksiyonel Gereksinimler

ID	Gereksinim	Açıklama
FR-01	Veri Girişi	Sistem VCF ve CSV formatlarında genetik varyant verisi kabul etmelidir.
FR-02	Veri Temizleme	Eksik değerler MICE algoritması ile doldurulmalı; aykırı değerler RobustScaler ile normalize
FR-03	Sınıflandırma	Her varyant Patojenik (1) veya Benign (0) olarak etiketlenmelidir.
FR-04	Risk Skoru	Sistem her varyant için 0-1 arasında bir risk olasılığı üretmelidir.

FR-05	Kural Motoru	CADD_PHRED ve AF_ESP eşik değerlerine dayalı medikal kural kontrolü yapılmalıdır.
FR-06	Açıklanabilirlik	Her tahmin için SHAP waterfall grafiği üretilmelidir.
FR-07	Model Kaydetme	Eğitilen modeller .pkl formatında kaydedilmelidir.

2.2 Fonksiyonel Olmayan Gereksinimler

ID	Kategori	Açıklama
NFR-01	Performans	Model eğitimi CPU üzerinde makul sürede tamamlanmalıdır.
NFR-02	Güvenilirlik	Yanlış Negatif (FN) oranı minimize edilmelidir; hasta kaçırma klinik açıdan kabul edilemez.
NFR-03	Açıklanabilirlik	Her tahmin klinisyen tarafından yorumlanabilir olmalıdır (SHAP grafiği).
NFR-04	Taşınabilirlik	Model .pkl ile dışa aktarılabilir ve farklı ortamlarda çalışabilir olmalıdır.
NFR-05	Sürdürülebilirlik	Kod modüler yapıda olmalı; her bileşen bağımsız geliştirilebilir olmalıdır.

4. Mimari Tasarım

VUSassistant, birbirinden bağımsız çalışabilen beş modülden oluşan katmanlı bir mimariye sahiptir. Her modül ayrı bir Python dosyasına karşılık gelir ve belirli bir sorumluluk alanını kapsar.

Katman	Modül / Dosya	Teknoloji	Sorumluluk
1 — Veri	veri_temizlik.py	pandas, sklearn IterativeImputer RobustScaler	Ham CSV okuma, MICE ile eksik doldurma, one-hot encoding, Risk_Indeksi türetme
2 — Model	makine_ogrenmesi.py	LightGBM, XGBoost Optuna, sklearn	Hiperparametre optimizasyonu (Optuna/30 deneme), 5-Fold CV, Dual-Core Ensemble eğitimi
3 — Kural	rule_engine.py	Saf Python	CADD_PHRED ve AF_ESP eşik kontrolü; güvenlik ağı
4 — XAI	xai_explainer.py	SHAP, matplotlib joblib	TreeExplainer ile SHAP waterfall grafiği üretimi
5 — Özellik	feature_list.json	JSON	Model-veri uyumunu garanti eden 118 özellik listesi
6— Frontend	index.html	HTML	Web sitesinin frontend kısmı
7 — Backend	main.py	PYTHON	Projenin tüm modüllerini birleştirip düzgün bir şekilde çalışmasını sağlayan dosya

4.1 Veri İşleme Pipeline'ı

Ham veri şu adımlardan geçerek modele hazır hale getirilir:

1. Ham CSV (61.000 satır) okunur — low_memory=False ile tip güvenliği sağlanır.
2. 9 sayısal + 8 kategorik sütun seçilir; gerisi düşürülür.
3. Kategorik sütunlar One-Hot Encoding ile sayısallaştırılır (toplam ~118 özellik).
4. MICE (Iterative Imputer) algoritması ile eksik değerler çok değişkenli tahmin yöntemiyledoldurulur.
5. Özel mühendislik: Risk_Indeksi = CADD_PHRED / (AF_ESP + 0.0001) türetilir.
6. RobustScaler ile aykırı değerlere dayanıklı normalizasyon uygulanır.
7. Nihai matris nihai_genetik_veri.csv olarak kaydedilir.

4.2 Model Mimarisi — Dual-Core Ensemble

Sistem, iki temel sınıflandırıcının Soft Voting Ensemble yöntemiyle birleştirilmesine dayanır:

Yardımcı Motor	XGBoost	Manuel hiperparametre (sabit ayarlar)	Çeşitlilik & dayanıklılık
Eşik Stratejisi	Dinamik Threshold	F2-Score eğrisi üzerinden auto-optimize	0.50 varsayılanı iptal; klinik karar eşiği

4.3 Kural Motoru (Güvenlik Ağı)

Yapay zekanın Benign (0) dediği durumlarda bile iki medikal kural devreye girerek klinisyeni uyarır. Bu katman, modelin kaçırabileceği kritik vakaları yakalamak için tasarlanmıştır:

Kural 1: Model=0 VE CADD_PHRED >= 20.0 → "Kritik CADD skoru — manuel inceleme gerek!"

Kural 2: Model=0 VE AF_ESP < 0.01 VE CADD_PHRED >= 15.0 → "Nadir varyant + yüksek CADD — gözden kaçmış olabilir!"

4.4 Açıklanabilirlik Katmanı (XAI)

Her tahmin için SHAP TreeExplainer kullanılarak waterfall grafiği üretilir. Bu grafik, hangi genetik özelliğin kararı ne yönde ve ne kadar etkilediğini klinisyene görsel olarak gösterir.

Çıktı base64 formatında web arayüzüne iletilir.

5. Sonuç ve Değerlendirme

VUSassistant projesi, klinik genetikte uzun süredir çözüm bekleyen VUS problemi için uygulanabilir, açıklanabilir ve güvenilir bir yapay zeka altyapısı sunmaktadır. Proje sürecinde elde edilen temel başarılar aşağıda özetlenmektedir:

Klinik Odaklı Optimizasyon	Varsayılan 0.50 karar eşiği kaldırılarak F2-Score üzerinden dinamik eşik belirlendi. Bu sayede Yanlış Negatif (FN) oranı — yani hasta kaçırma — minimize edildi.
İki Katmanlı Güvenlik	Makine öğrenmesi modelinin yanına kural tabanlı bir güvenlik ağı eklendi. Böylece modelin gözden kaçırabileceği kritik varyantlar için ikinci bir kontrol mekanizması sağlandı.
Açıklanabilirlik	SHAP waterfall grafikleri sayesinde sistem kara kutu olmaktan çıktı. Her karar, klinisyenin anlayabileceği özellik önem sıralamalarıyla desteklendi.
Modüler Yazılım Mimarisi	Veri temizleme, model eğitimi, kural motoru ve XAI katmanları birbirinden bağımsız modüller olarak tasarlandı. Bu yapı gelecekteki bakım ve geliştirme süreçlerini kolaylaştırmaktadır.
Ensemble Yaklaşımı	LightGBM ve XGBoost modellerinin Soft Voting ile birleştirilmesi, tek modele kıyasla daha kararlı ve genellenebilir tahmin performansı sağladı.

6. Gelecek Çalışmalar

1. Toplu Veri Yükleme: Doktorların hastaların verilerini dosya halinde yükleme seçeneği.
2. Bulut Entegrasyonu: AWS/Azure üzerinde ölçeklenebilir GPU desteği.
3. KVKK Modülü: Sağlık verileri için gelişmiş anonimleştirme algoritmaları.